

Klasifikasi Jenis Kanker Otak dengan Menggunakan Model Densenet-201, Resnet-50 dan VGG-19

1st Rennu Aq'sha Sanjaya

dept. of Information Technology

Universitas Muhammadiyah

Yogyakarta

Yogyakarta, Indonesia

Rennu.aqsha.ft21@mail.umy.ac.id

2nd Qodri Aziz

dept. of Electrical Engineering and

Information Technology

Universitas Gadjah Mada

Yogyakarta, Indonesia

qodriaziz@mail.ugm.ac.id

3rd Khairun Nisa

dept. of Electrical Engineering and

Information Technology

Universitas Gadjah Mada

Yogyakarta, Indonesia

khairunnisa0699@mail.ugm.ac.id

4th Slamet Riyadi

dept. of Information Technology

Universitas Muhammadiyah

Yogyakarta

Yogyakarta, Indonesia

riyadi@mail.umy.ac.id

Abstract— Kanker otak merupakan salah satu jenis penyakit serius yang memengaruhi fungsi vital tubuh dan menjadi tantangan utama dalam dunia medis. Penyakit ini mencakup beberapa jenis, seperti Brain Glioma, Brain Meningioma, dan Brain Tumor, yang membutuhkan diagnosis dini dan akurat untuk meningkatkan kualitas hidup pasien. Penelitian ini bertujuan untuk mengklasifikasikan tiga jenis kanker otak tersebut menggunakan tiga arsitektur jaringan saraf konvolusional (CNN) berbasis deep learning, yaitu DenseNet201, ResNet50, dan VGG19. Dataset yang digunakan adalah citra MRI T1-weighted contrast-enhanced yang diunduh dari Kaggle, dengan preprocessing berupa resizing, normalisasi, dan augmentasi data untuk meningkatkan performa model. Model DenseNet201 menunjukkan performa terbaik dengan akurasi sebesar 99,50% dan akurasi validasi mencapai 98%, yang mencerminkan kemampuan model dalam mempelajari pola dengan efisien tanpa tanda-tanda overfitting. Sebaliknya, model ResNet50 mengalami overfitting yang signifikan. Akurasi pada pelatihan mencapai 37,25%, akurasi validasi hanya berada di kisaran 35%-40%, yang menandakan bahwa model ini tidak mampu menangkap pola relevan pada data validasi. Kemudian pada model VGG19 memberikan hasil yang cukup baik dibandingkan ResNet50, dengan akurasi validasi mendekati 91,25% dan tren loss yang konsisten tanpa overfitting. Penelitian ini menyimpulkan bahwa DenseNet201 adalah model yang paling efektif untuk tugas klasifikasi tiga jenis kanker otak dengan menggunakan dataset MRI. Performa tinggi yang ditunjukkan oleh DenseNet201 menjadikannya kandidat yang potensial untuk diimplementasikan dalam sistem medis untuk diagnosis dini.

Keywords—Brain Cancer, Deep Learning, DenseNet201, Medical Imaging, MRI Classification, ResNet50, Transfer Learning, VGG19.

I. INTRODUCTION (HEADING 1)

Kanker otak, salah satu jenis kanker paling umum dan serius, menjadi tantangan kesehatan global karena dampaknya pada sistem saraf yang mengatur fungsi vital tubuh. Kanker ini mencakup sekitar 3% dari semua kasus kanker di dunia dengan variasi geografis yang signifikan, di mana tingkat kejadian lebih tinggi di wilayah maju seperti Eropa dan Amerika Utara dibandingkan dengan daerah berkembang seperti Afrika dan Asia. Faktor seperti kemajuan alat diagnostik, predisposisi genetik, dan pengaruh lingkungan berkontribusi pada perbedaan ini. Tren peningkatan kasus kanker otak secara global menunjukkan pentingnya memahami epidemiologi dan faktor risikonya

untuk mendukung langkah-langkah pencegahan dan pengobatan[1].

Glioma, tumor otak yang berasal dari sel glial, adalah salah satu jenis kanker otak yang mencakup glioblastoma (GBM), bentuk paling agresif. Glioma sering melibatkan interaksi kompleks antara sel tumor dan mikrolingkungan, seperti sitokin IL-33 yang dapat merekrut makrofag protumorigenik dan mempercepat pertumbuhan tumor. Secara umum, tumor otak mencakup berbagai pertumbuhan abnormal yang dapat bersifat jinak atau ganas, dengan dampak seperti tekanan intrakranial meningkat atau kerusakan jaringan otak. Tumor otak sulit diobati karena sawar darah-otak, resistensi sel tumor, dan heterogenitas mikrolingkungan tumor, sehingga penelitian terbaru berfokus pada pendekatan yang mempertimbangkan interaksi tumor dengan sistem imun tubuh. Brain Meningioma Meningioma adalah jenis tumor otak yang berasal dari meninges, lapisan pelindung yang melapisi otak dan sumsum tulang belakang. Meningioma biasanya bersifat jinak, tetapi dapat menjadi ganas dalam kasus tertentu. Tumor ini tumbuh perlahan dan sering kali tidak menunjukkan gejala pada tahap awal. Namun, seiring pertumbuhannya, meningioma dapat menekan jaringan otak atau saraf kranial, menyebabkan berbagai gejala seperti sakit kepala, gangguan penglihatan, atau kelemahan pada tubuh. Pengobatan meningioma tergantung pada ukuran, lokasi, dan sifat tumor, dengan opsi utama termasuk pembedahan, terapi radiasi, atau observasi untuk kasus yang tidak bergejala. Tumor ini cenderung lebih sering terjadi pada wanita dan memiliki hubungan dengan paparan radiasi serta mutasi genetik tertentu seperti pada gen NF2.

II. RELATED WORKS

A. Riset Terdahulu

Penelitian oleh Tandel et al. berjudul "A Review on a Deep Learning Perspective in Brain Cancer Classification" menggunakan metode seperti machine learning (ML) dan deep learning (DL) untuk karakterisasi otomatis jaringan dan segmentasi tumor otak. Dataset mencakup berbagai citra otak yang dihasilkan oleh teknik pencitraan seperti MRI, CT, dan PET. Penelitian ini mengidentifikasi kesenjangan dalam metode eksisting, seperti variabilitas antar pembaca, ketergantungan pada keahlian patologis, dan keterbatasan data, untuk mengembangkan alat berbasis komputer yang lebih akurat dan efisien dalam diagnosis kanker otak secara non-invasif.[1]

Penelitian ini dilakukan oleh Boeck et al. berjudul "*IL-33 Drives Glioblastoma Progression by Regulating the Tumor Microenvironment*" menggunakan metode seperti single-cell RNA sequencing (scRNA-seq), phosphoproteomics, uji fungsional in vitro, dan model tikus xenograft. Dataset penelitian ini berasal dari sumber seperti GEO (Gene Expression Omnibus) dan EGA (European Genome-phenome Archive). Penelitian ini mengisi celah penelitian sebelumnya dengan mengeksplorasi secara mendalam peran IL-33 dalam mengatur dinamika mikroglia dan makrofag di glioblastoma, yang sebelumnya kurang dipahami. [2]

Penelitian oleh Nagaraj et al. berjudul "Programmed Multi-Classification of Brain Tumor Images Using Deep Neural Network" menggunakan metode deep learning berbasis Convolutional Neural Network (CNN) untuk klasifikasi multi-kelas tumor otak. Dataset yang digunakan mencakup gambar MRI publik, dengan klasifikasi berdasarkan jenis tumor (Meningioma, Glioma, dan Pituitari) serta tingkatannya (Grade II, III, IV). Dataset melalui proses pre-processing, termasuk resizing ke ukuran 128x128x3 piksel untuk mempercepat proses pelatihan. Model CNN yang digunakan terdiri dari 16 lapisan dengan penggunaan fungsi aktivasi ReLU, max pooling, dan dropout untuk mencegah overfitting. Penelitian ini menunjukkan akurasi tertinggi sebesar 96.13% untuk klasifikasi tipe tumor dan 98.7% untuk klasifikasi tingkat tumor, membuktikan efektivitas CNN dalam diagnosis kanker otak berbasis gambar MRI.[3]

Penelitian oleh Vijayakumar et al. berjudul "*Classification of Brain Cancer Type Using Machine Learning*" menggunakan Capsule Neural Network (CapsNet) untuk mengklasifikasikan jenis kanker otak berdasarkan data MRI. Metode ini memanfaatkan dataset TCGA-GBM dari The Cancer Imaging Archive (TCIA) dan menunjukkan bahwa CapsNet dapat mengatasi masalah rotasi dan transformasi affine yang sering dihadapi oleh CNN. Dengan pelatihan menggunakan data yang lebih sedikit, CapsNet mencapai akurasi yang lebih tinggi dibandingkan dengan model lain seperti CNN, NN, dan ResNet. Kesenjangan penelitian sebelumnya yang diatasi adalah kebutuhan akan dataset besar dan kehilangan posisi input akibat pooling dalam CNN. CNN, tabel menunjukkan persentase akurasi pelatihan (training) dan pengujian (testing) dibandingkan dengan metode lain. Namun, angka pastinya seperti 78% atau 85%. Studi ini membuka peluang untuk klasifikasi kanker otak yang lebih efisien dan akurat[4]

Penelitian oleh Sadad et al. dalam penelitiannya yang berjudul "Brain Tumor Detection and Multi-Classification Using Advanced Deep Learning Techniques" memfokuskan pada deteksi dan klasifikasi tumor otak menggunakan pendekatan deep learning. Metode utama yang digunakan adalah arsitektur DenseNet201 (93,1%), ResNet50 (92,9%), InceptionV3 (92,8%), dan MobileNetV2 (91,8%). dengan tambahan data augmentation dan transfer learning untuk meningkatkan kinerja model. Dataset yang digunakan adalah Figshare dataset, yang mencakup 3.064 citra MRI dari 233 pasien, dengan tiga jenis tumor utama (glioma, pituitary, dan meningioma) serta tiga tampilan berbeda (sagittal, axial, coronal).[5]

Penelitian dilakukan oleh Muhammad et al. tentang klasifikasi multigrade tumor otak menggunakan teknik preprocessing, augmentasi data, transfer learning, dan

arsitektur CNN dengan akurasi 87% pada dataset publik (BraTS, TCIA, dll.), Shirazi et al. (2020) mengembangkan DeepSurvNet berbasis arsitektur GoogleNet untuk memprediksi tingkat kelangsungan hidup pasien kanker otak dengan presisi 99% menggunakan dataset TCGA dan dataset privat, dan Sidong et al. (2020) yang memanfaatkan kombinasi GAN dan ResNet50 untuk prediksi mutasi IDH dengan akurasi 85,3% pada dataset TCGA dan dataset privat, namun penelitian-penelitian ini menunjukkan adanya celah seperti kurangnya integrasi pencitraan histopatologi dalam segmentasi dan perlunya peningkatan akurasi dengan fitur tambahan seperti usia pasien.[6]

Penelitian dilakukan oleh Sowrirajan et al. yang mengembangkan model hybrid VGG16-NADE untuk klasifikasi tumor otak dengan metode pengolahan data MRI berbasis deep learning, menghasilkan akurasi 96,01% menggunakan dataset T1-weighted contrast-enhanced MRI, mengatasi keterbatasan model sebelumnya seperti CNN-Genetic Algorithm atau CNN-KELM dalam hal sensitivitas dan F1 score, tetapi masih terdapat peluang untuk meningkatkan akurasi dan efisiensi dengan arsitektur yang lebih kompleks seperti VGG19.[7]

Penelitian oleh Aulia dan Rahmat et al. mengembangkan metode identifikasi tumor otak berbasis arsitektur VGG-16 dan teknik peningkatan kontras CLAHE, dengan hasil akurasi 90,37%, presisi 90,22%, dan recall 87,61% pada dataset MRI otak dari Kaggle, meskipun masih menghadapi tantangan dalam mengurangi prediksi positif palsu dan meningkatkan kinerja pada kelas tertentu seperti oligodendroglioma[8]

Studi oleh Alshammari et al. pada tahun melakukan penelitian berjudul "Construction of VGG16 Convolution Neural Network (VGG16_CNN) Classifier with NestNet-Based Segmentation Paradigm for Brain Metastasis Classification" menggunakan metode deep learning dengan VGG16_CNN dan segmentasi NestNet, mencapai akurasi 93,74%, presisi 92%, recall 92,1%, dan F1-score 67,08%, menggunakan dataset MRI mencakup meningioma, glioma, dan tumor pituitari sebanyak 3064 gambar, dengan gap penelitian berupa perbaikan diagnosis metastasis otak kecil dan mengatasi ketidakseimbangan kelas pada dataset melalui softmax berbobot[9]

Studi penelitian Tian C et al. dan rekan-rekan pada tahun mengembangkan model klasifikasi tumor otak berbasis Enhanced VGG19 CNN dengan mengganti lapisan Softmax dengan SVM dan menggunakan transfer learning, menghasilkan akurasi 95% melalui metode validasi silang sepuluh kali lipat untuk meningkatkan generalisasi, menunjukkan kinerja unggul dalam diagnosis akurat dan cepat untuk CNS-pDLBCL dan HGG.[10]

Studi penelitian Srinivas et al. pada tahun menggunakan pendekatan transfer learning berbasis deep learning dengan model pra-latih VGG-16, ResNet-50, dan Inception-v3 untuk klasifikasi tumor otak menggunakan gambar MRI, mencapai akurasi tertinggi 96% pada model VGG-16 dengan data augmentasi untuk meningkatkan ukuran dataset kecil, menekankan efisiensi diagnosis tumor otak melalui analisis gambar otomatis.[11]

Penelitian dilakukan oleh Raza et al. dan tim pada tahun mengembangkan model hybrid DeepTumorNet berbasis deep learning dengan modifikasi GoogLeNet yang menambahkan 15 lapisan baru untuk klasifikasi glioma, meningioma, dan

tumor pituitari pada dataset MRI, mencapai akurasi 99,67%, presisi 99,6%, recall 100%, dan F1-score 99,66%, dengan penekanan pada efisiensi deteksi otomatis tumor otak.[12]

Penelitian dilakukan M. Alhassan et al. mengembangkan metode segmentasi dan klasifikasi tumor otak berbasis algoritma Bat dengan Fuzzy C-Ordered Means (BAFCOM) untuk segmentasi dan Enhanced Capsule Networks (ECN) untuk klasifikasi, mencapai akurasi 95,81%, presisi 94,83%, recall 94,34%, dan F1-score 94,59% pada dataset MRI sebanyak 2065 gambar, dengan fokus pada peningkatan diagnosis otomatis tumor otak melalui pendekatan deep learning.[13]

Studi penelitian Mercaldo et al. menggunakan model deteksi objek YOLOv8 untuk mendeteksi dan melokalisasi kanker otak dari citra MRI, mencapai presisi 94,3%, recall 93,2%, dan mAP@0.5 sebesar 94,1% pada dataset 300 citra MRI, dengan penekanan pada kecepatan dan akurasi untuk diagnosis kanker otak yang lebih cepat dan efektif.[14]

Studi penelitian Florimbi et al. mengembangkan sistem deteksi kanker otak berbasis Hyperspectral Imaging (HSI) dengan platform multi-GPU untuk operasi intraoperatif, mencapai akurasi klasifikasi sebesar 95% dan waktu pemrosesan kurang dari tiga detik untuk gambar terbesar dalam database, memastikan respons real-time dengan akurasi tinggi dalam membedakan jaringan tumor, normal, dan hipervaskular.[15]

Penelitian dilakukan oleh Afshar et al. mengembangkan arsitektur Capsule Network (CapsNet) untuk klasifikasi tumor otak menggunakan gambar MRI, yang mencakup batas kasar tumor sebagai input tambahan, dan mencapai akurasi 90,89%, menunjukkan peningkatan performa dibandingkan CapsNet dan CNN konvensional dalam mengidentifikasi meningioma, glioma, dan tumor pituitari.[16]

Studi penelitian oleh Attique Khan et al. sistem klasifikasi tumor otak berbasis deep learning menggunakan teknik transfer learning pada model VGG16 dan VGG19, dengan proses seleksi fitur robust berbasis ELM dan fusi fitur berbasis PLS, yang mencapai akurasi 98,16% pada dataset BRATS2015, 97,26% pada dataset BRATS2017, dan 93,40% pada dataset BRATS2018, menunjukkan efisiensi tinggi dalam klasifikasi tumor otak multimodal.[17]

Penelitian dilakukan oleh M. Badža et al. mengembangkan arsitektur CNN baru untuk klasifikasi tumor otak menggunakan gambar MRI T1-weighted contrast-enhanced, yang mencapai akurasi 96,56% pada dataset yang ditingkatkan dengan validasi silang 10-lipat, menunjukkan efisiensi tinggi dalam klasifikasi meningioma, glioma, dan tumor pituitari.[18]

Penelitian dilakukan oleh Kumar et al. mengembangkan metode Dolphin-SCA berbasis Deep CNN untuk segmentasi dan klasifikasi tumor otak menggunakan gambar MRI, yang mencapai akurasi 96,3% pada dataset BRATS dan SimBRATS, menunjukkan efisiensi tinggi dalam mengidentifikasi tumor dengan tingkat kecepatan dan akurasi yang baik. [19]

Penelitian dilakukan oleh H. Sultan et al. mengembangkan arsitektur CNN khusus untuk klasifikasi tumor otak berdasarkan gambar MRI, mencapai akurasi 96,13% pada klasifikasi meningioma, glioma, dan tumor pituitari, serta akurasi 98,7% pada klasifikasi glioma berdasarkan grade, menunjukkan kemampuan tinggi dalam multi-klasifikasi tumor otak.[20]

Studi penelitian oleh Kang et al. mengembangkan metode klasifikasi tumor otak berbasis MRI menggunakan ensemble deep features dari 13 model CNN pra-latih dan 9 jenis klasifikasi machine learning, mencapai akurasi 98,83% pada dataset dengan dua kelas (normal dan tumor) dan 91,58% pada dataset dengan empat kelas (normal, glioma, meningioma, dan tumor pituitari), menunjukkan peningkatan kinerja klasifikasi secara signifikan melalui pendekatan ensemble learning.[21]


Penelitian-penelitian ini bertujuan untuk meningkatkan akurasi dan efisiensi segmentasi serta klasifikasi tumor otak menggunakan metode berbasis deep learning, machine learning, transfer learning, dan teknik hybrid pada citra MRI. Selain itu, penelitian ini juga berupaya mengatasi keterbatasan dataset kecil, menyediakan diagnosis real-time, dan mendukung tenaga medis dalam pengambilan keputusan klinis melalui pengembangan alat bantu diagnostik berbasis kecerdasan buatan.

Penelitian yang ada menunjukkan perbedaan signifikan ketika menggunakan arsitektur CNN dan yang lainnya teknik transfer learning untuk mengklasifikasikan gambar medis, seperti deteksi kanker otak. Meskipun hasilnya cukup menggalakkan, ada beberapa tindakan pencegahan yang harus dipertimbangkan. Pertama, banyak penelitian menggunakan dataset yang tidak stabil, yang berarti hasilnya mungkin tidak umum untuk populasi atau negara yang lebih tersebar luas di dunia. Selain itu, bahkan jika kondisi eksperimen dipenuhi dengan tingkat akurasi yang tinggi, implementasi praktis dalam pengaturan klinis tidak dilakukan secara luas.

Selain itu, sementara teknik augmentasi data telah digunakan dalam beberapa penelitian untuk meningkatkan kinerja model, mereka juga dapat menyebabkan overfitting jika tidak diterapkan dengan benar. Kekuatan komputasi yang tinggi diperlukan untuk mengembangkan model kompleks yang dapat diimplementasikan dalam berbagai lingkungan. Penilaian yang lebih komprehensif menggunakan metrik yang relevan dan analisis perbandingan yang lebih luas masih diperlukan. Akhirnya, masalah penyimpanan data dan kemampuan implementasi real-time juga perlu diperiksa lebih dekat untuk memastikan bahwa model yang dikembangkan dapat diterapkan secara efektif dalam skenario klinis dunia nyata.

III. METHOD

Metode ini digunakan untuk memprediksi dan mengklasifikasi Kanker Otak menggunakan arsitektur Convolutional Neural Network (CNN) yaitu Densenet201, VGG19 dan ResNet50 dengan menggunakan Multi Cancer dataset Brain Cancer dari Kaggle.com seperti pada Gambar 1




Gambar 1. Flowchart Alur Analisis

A. Pengumpulan Data


Dataset yang digunakan adalah Multi Cancer - Brain Cancer, yang mencakup tiga kelas berbeda: tiga jenis tumor otak: Meningioma, Glioma, dan tumor Hipofisis, yang diolah untuk klasifikasi jenis Kanker Otak. Dataset dapat dilihat pada link

https://figshare.com/articles/dataset/brain_tumor_dataset/1512427) Dataset tumor otak ini berisi 3064 gambar yang ditingkatkan kontras berbobot T1 dari 233 pasien dengan tiga jenis tumor otak: meningioma (708 irisan), glioma (1426 irisan), dan tumor hipofisis (930 irisan). Contoh dari gambar dataset Brain Cancer dapat dilihat pada gambar 2. Kode sumber yang digunakan dapat diakses di tautan github: https://github.com/Rennuaqsha/Code_BrainCancer.git



Gambar 2. Tiga jenis Kanker otak

Semua yang ada pada Gambar 2 dalam dataset kami (T1-weighted contrast-enhanced MRI) diakuisisi setelah injeksi Gd-DTPA di Rumah Sakit Nanfang, Guangzhou, Cina dan Rumah Sakit Umum, Universitas Kedokteran Tianjin, Cina dari tahun 2005.9 hingga 2010.10. Gambar memiliki resolusi dalam bidang 512×512 dengan dimensi piksel $0,49 \times 0,49$ mm². Ketebalan irisan adalah 6 mm dan celah irisan adalah 1 mm. Dosis Gd adalah 0,1 mmol/kg pada kecepatan 2 ml/s.



Gambar 3. Alur PreProcessing

B. Data Preparation

Penelitian ini bertujuan untuk memprediksi dan mengklasifikasikan Brain Cancer menjadi tiga kelas, yaitu Meningioma, Glioma, dan tumor Hipofisis menggunakan arsitektur Convolutional Neural Network (CNN) berbasis DenseNet201. Dataset yang digunakan adalah gambar (T1-weighted contrast-enhanced MRI) yang diambil dari situs Kaggle.com, dengan jumlah 3064 yang diproses untuk melatih dan menguji model. Tahapan preprocessing data dapat dilihat pada Gambar 3.

Proses pada gambar menunjukkan pengolahan data pada penelitian ini dilakukan melalui beberapa tahapan utama, seperti yang digambarkan pada flowchart. Tahap pertama adalah Memilih Data, di mana dataset multi-kanker diunduh dari Kaggle menggunakan pustaka kagglehub dan dimuat menggunakan fungsi `load_files`. Dataset ini terdiri dari beberapa kategori kanker, dan untuk memastikan efisiensi serta keragaman data, sebanyak 800 gambar dipilih secara acak dari total dataset menggunakan fungsi `np.random.choice`. Hal ini bertujuan untuk mengurangi waktu komputasi tanpa mengurangi representasi dataset.

Tahap berikutnya adalah Konversi Data, di mana path file gambar yang telah dipilih dikonversi menjadi array numerik menggunakan fungsi `load_img` dan `img_to_array`. Fungsi ini mengubah setiap gambar menjadi array tiga dimensi yang merepresentasikan nilai piksel pada format RGB. Proses ini penting untuk menjadikan gambar dalam format yang dapat diproses oleh model deep learning.

Selanjutnya, dilakukan Resizing Data untuk standar ukuran gambar ke dimensi 224x224 piksel. Ukuran ini dipilih karena merupakan resolusi input yang kompatibel dengan model deep learning populer seperti DenseNet201 yang digunakan pada penelitian ini. Resizing dilakukan secara langsung selama proses konversi dengan menggunakan parameter `target_size` pada fungsi `load_img`.

Tahap keempat adalah One-Hot Encoding, di mana label target yang awalnya dalam bentuk integer dikonversi ke format one-hot encoding menggunakan fungsi `to_categorical`. Dalam format ini, setiap label diubah menjadi vektor biner dengan nilai 1 pada indeks yang sesuai dengan kelasnya, sementara indeks lainnya diisi dengan nilai 0. Hal ini dilakukan agar model dapat memproses label dalam konteks klasifikasi multi-kelas.

Table 1. Splitting Data

Train	Valid	Test
-------	-------	------


640	160	800
-----	-----	-----

Tahap terakhir adalah splitting data terlihat pada Tabel 1, yaitu membagi dataset menjadi tiga subset: data latih, data validasi, dan data Test. Pembagian ini dilakukan menggunakan fungsi `train_test_split` dengan rasio 40:10:50 untuk data latih, validasi dan Test. Proses ini memastikan bahwa model dilatih menggunakan data latih, diuji performanya pada data validasi, dan dievaluasi akhirnya menggunakan data uji untuk menghindari overfitting dan mengukur generalisasi model secara objektif. Keseluruhan proses ini bertujuan untuk mempersiapkan data agar dapat digunakan dalam pelatihan model deep learning dengan format yang sesuai dan memastikan distribusi data yang optimal untuk mendukung performa model yang baik.

C. Arsitektur Model

Proses pengolahan data dan pelatihan model dimulai dengan persiapan data yang mencakup langkah-langkah seperti Initializing, Transfer Learning, Complication Model dan Training Model. Proses dapat dilihat pada gambar 4.

Proses pengolahan data dalam kode dalam bentuk flow seperti pada gambar, yang melibatkan beberapa langkah utama. Proses dimulai dengan memilih data dari dataset yang tersedia, di mana dataset gambar diunduh dari sumber eksternal menggunakan Kaggle API. Setelah data berhasil diunduh langkah berikutnya adalah konversi data.



Gambar 4. Gambar Arsitektur Model

Dalam tahap ini, data gambar diubah menjadi array numerik menggunakan fungsi seperti `img_to_array` untuk memungkinkan manipulasi dan analisis lebih lanjut seperti pada Gambar 4. Kemudian, dilakukan resizing data ke ukuran yang seragam, yaitu 224x224 piksel, agar sesuai dengan persyaratan masukan model pretrained seperti VGG19, ResNet50, atau DenseNet201. Selanjutnya, proses one-hot encoding diterapkan pada label untuk mengonversi nilai target menjadi representasi vektor biner, yang diperlukan untuk tugas klasifikasi dengan lebih dari satu kelas. Setelah itu, dataset dibagi menjadi tiga bagian utama melalui proses splitting data, yaitu data latih, validasi, dan uji, dengan tujuan memastikan model dapat belajar secara efektif dari data latih sambil mempertahankan kemampuan generalisasi pada data uji. Proses ini diakhiri dengan memastikan data siap digunakan untuk pelatihan model berbasis transfer learning.

Proses dimulai dengan langkah Initializing. Pada tahap ini, sistem atau model dipersiapkan, termasuk konfigurasi awal, pengaturan parameter, dan penyiapan data yang akan


digunakan dalam proses berikutnya. Setelah proses inisialisasi selesai, langkah berikutnya adalah Transfer Learning, di mana model yang sudah dilatih sebelumnya pada dataset besar digunakan sebagai dasar. Transfer learning memungkinkan efisiensi dalam pelatihan model, terutama jika dataset spesifik yang digunakan relatif kecil.

Tahap selanjutnya adalah Complication Model, yang mengacu pada proses menyusun model dengan menambahkan lapisan, parameter, atau arsitektur khusus untuk menyesuaikan model agar dapat menyelesaikan masalah spesifik yang sedang dihadapi. Langkah ini penting untuk memastikan bahwa model tidak hanya mengandalkan fitur bawaan dari transfer learning, tetapi juga mampu menangani kompleksitas data baru.

Setelah model dikompilasi, langkah terakhir adalah Training Model. Pada tahap ini, model dilatih menggunakan dataset yang telah dipersiapkan. Proses pelatihan melibatkan optimasi parameter model untuk meminimalkan kesalahan dan meningkatkan performa prediksi. Setelah pelatihan selesai, proses diakhiri, dan model siap untuk digunakan. Model yang digunakan adalah DenseNet 201, ResNet-50 dan VGG19.

1. DenseNet (Dense Convolutional Network)


DenseNet adalah arsitektur jaringan saraf konvolusional yang memperkenalkan pendekatan unik dalam penghubungan lapisan. Pada DenseNet, setiap lapisan terhubung langsung dengan semua lapisan berikutnya dalam blok jaringan yang sama.[22] Keunggulan utama DenseNet adalah konektivitas padat, di mana setiap lapisan terhubung langsung ke semua lapisan berikutnya, memungkinkan penggunaan ulang fitur, penyebaran gradien yang lebih baik, dan pengurangan jumlah parameter tanpa mengurangi akurasi. Pendekatan ini membuat DenseNet sangat cocok untuk digunakan pada dataset dengan jumlah terbatas, karena dapat mengurangi risiko overfitting. DenseNet sering digunakan dalam aplikasi medis dan industri, termasuk dalam analisis citra medis seperti mendeteksi kanker atau kelainan lain, serta dalam transfer learning untuk berbagai tugas pembelajaran mesin. Keunikan densenet terletak pada konektivitas langsung (direct connection) antar lapisan di dalam jaringan, di mana setiap lapisan akan menerima input dari semua lapisan sebelumnya. Ini memberikan keuntungan berupa peningkatan aliran informasi dan gradien di dalam jaringan, sehingga densenet mampu mencapai performa yang baik dengan jumlah parameter yang relatif Blok pertama memiliki enam lapisan, blok kedua memiliki dua belas lapisan, blok ketiga memiliki empat puluh delapan lapisan, dan blok keempat memiliki tiga puluh dua lapisan. Setiap blok diikuti oleh lapisan transisi yang mencakup konvolusi 1x1 untuk pengurangan dimensi dan average pooling 2x2 untuk mengurangi resolusi fitur. Akhirnya, lapisan Global Average Pooling (GAP) digunakan untuk mereduksi fitur menjadi vektor tunggal, yang diteruskan ke lapisan Dense dengan fungsi aktivasi softmax untuk klasifikasi multi-kelas. Untuk penelitian ini, lapisan awal DenseNet-201 dibekukan untuk mempertahankan bobot yang telah dilatih sebelumnya pada dataset ImageNet, dan kepala klasifikasi khusus ditambahkan yang mencakup GAP, Dropout (dengan tingkat 0.2), dan lapisan Dense.




Gambar 5. Arsitektur Model DenseNet20

2. ResNet-50 (Residual Network-50)

ResNet-50 adalah arsitektur deep learning yang dirancang untuk mengatasi masalah vanishing gradient pada jaringan neural yang sangat dalam, dengan memperkenalkan konsep residual learning melalui koneksi shortcut atau skip connection. Arsitektur ini terdiri dari lima blok residual utama, di mana blok pertama memiliki 3 lapisan, blok kedua memiliki 4 lapisan, blok ketiga memiliki 6 lapisan, dan blok keempat memiliki 3 lapisan, masing-masing dilengkapi dengan convolutional layer (kernel 1x1 dan 3x3), batch normalization, dan ReLU activation. Setelah setiap blok, input awal dijumlahkan dengan output transformasi untuk memungkinkan penyebaran gradien yang lebih baik dan mengurangi risiko overfitting. Model ini menggunakan Global Average Pooling (GAP) untuk mereduksi fitur menjadi vektor tunggal, diikuti oleh Dropout dengan tingkat 0.2, dan lapisan Dense dengan fungsi aktivasi softmax untuk klasifikasi multi-kelas. Dalam penelitian ini, lapisan awal ResNet-50 dibekukan untuk mempertahankan bobot yang telah dilatih sebelumnya pada dataset ImageNet, sementara kepala klasifikasi khusus ditambahkan untuk mendukung tugas pembelajaran yang lebih spesifik. Keunggulan utama ResNet-50 terletak pada efisiensi parameter dan kemampuannya menangani dataset dengan jumlah terbatas, sehingga sangat cocok untuk aplikasi seperti klasifikasi citra medis, deteksi objek, dan transfer learning di berbagai domain.



Gambar 6. Arsitektur Model. ResNet50



Gambar 7. Arsitektur model VGG19

3. VGG19

VGG19 adalah arsitektur Convolutional Neural Network (CNN) yang dirancang oleh Visual Geometry Group (VGG) dari University of Oxford untuk tugas pengenalan gambar, dengan total 19 lapisan yang terdiri dari 16 lapisan convolusi, 3 lapisan fully connected, dan satu lapisan softmax untuk klasifikasi. Model ini menggunakan filter 3x3 dengan padding *same* dan pooling 2x2 untuk menjaga kesederhanaan sekaligus meningkatkan ekstraksi fitur. VGG19 menerima gambar masukan berukuran 224x224x3 dan memiliki keunggulan berupa desain sederhana, modular, serta performa yang kuat, meskipun memerlukan sumber daya besar dengan sekitar 143 juta parameter, yang membuatnya berat secara komputasi dan rentan overfitting jika data latih terbatas.

D. Matrik Evaluasi

Dalam proses pengembangan model pembelajaran mesin, evaluasi kinerja model merupakan langkah krusial untuk memastikan efektivitas dan akurasi prediksi. Metrik evaluasi digunakan untuk mengukur seberapa baik model dalam memprediksi data baru dan memberikan gambaran mendalam tentang performa model dalam berbagai aspek. Sub bab ini akan membahas berbagai metrik yang digunakan untuk mengevaluasi hasil model, seperti akurasi, presisi, recall, F1-score, dan matriks kebingungan, yang membantu dalam memahami kekuatan dan kelemahan model yang telah dibangun.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \times 100 \quad (1)$$

$$Sensitivity = \frac{TP}{TP+FN} \times 100 \quad (2)$$

$$Specificity = \frac{TN}{TN+FP} \times 100 \quad (3)$$

$$Accuracy = \frac{TP+FP}{TP+FP} \times 100 \quad (4)$$

$$F1 - Score = 2 \times \frac{Sensitivity \times Precision}{Sensitivity + Precision} \times 100\% \quad (5)$$

1. Accuracy

Akurasi adalah ukuran seberapa banyak prediksi yang benar dari data yang diuji secara keseluruhan. Metrik ini sering digunakan sebagai indikator awal performa model karena mencakup prediksi benar untuk kelas positif dan negatif.

2. Sensitivity

Sensitivity, atau Recall, mengukur kemampuan model untuk mengidentifikasi data positif dari semua data yang sebenarnya positif. Metrik ini penting dalam kasus seperti deteksi penyakit atau fraud, di mana kegagalan untuk mendeteksi kasus positif memiliki konsekuensi serius.

3. Specifity

Specifity mengukur kemampuan model untuk menemukan data negatif dari semua data negatif yang

sebenarnya. Metrik ini menunjukkan seberapa baik model menemukan sampel negative.

4. Precision

Precision menunjukkan seberapa akurat prediksi positif yang dihasilkan oleh model, yaitu proporsi prediksi positif yang benar dari semua prediksi positif. Precision yang tinggi menunjukkan bahwa model jarang menghasilkan prediksi positif palsu.

5. F1-Score

F1-Score adalah metrik evaluasi yang menggabungkan Precision dan Recall dalam satu nilai dengan menghitung rata-rata harmonis keduanya. Metrik ini mengimbangi kemampuan model untuk mendeteksi data positif (Recall) dan menghasilkan prediksi positif yang akurat (Precision).

IV. IMPLEMENTASI

Bab implementasi dalam penelitian ini menjelaskan proses implementasi kodingan di lingkungan google colab, dengan pengaturan library dan runtime. Arsitektur model dalam kode ini mengadopsi pendekatan transfer learning dengan menggunakan model DenseNet201, ResNet-50 dan VGG19. DenseNet201 adalah salah satu arsitektur jaringan saraf konvolusional (CNN) yang menghubungkan setiap lapisan ke semua lapisan sebelumnya melalui koneksi langsung. Pendekatan ini memungkinkan aliran informasi yang lebih baik di dalam jaringan, mengurangi risiko kehilangan informasi penting, dan meningkatkan efisiensi parameter. Model ini menerima input gambar berukuran 224x224 piksel dengan tiga saluran warna (RGB), yang di-rescale agar nilainya berada dalam rentang 0 hingga 1.

Dalam implementasi ini, lapisan awal DenseNet201 yang telah dilatih pada dataset ImageNet dibekukan untuk mempertahankan fitur dasar yang telah dipelajari sebelumnya. Kemudian, lapisan tambahan ditambahkan di atasnya untuk menyesuaikan model dengan tugas klasifikasi pada dataset multi-cancer. Lapisan tambahan tersebut mencakup GlobalAveragePooling2D, yang meratakan keluaran dari DenseNet201 untuk mengurangi dimensi fitur. Setelah itu, ditambahkan Dropout layer dengan tingkat dropout 20% untuk mengurangi overfitting dengan menonaktifkan sejumlah neuron selama pelatihan. Lapisan terakhir adalah Dense layer dengan fungsi aktivasi softmax yang menghasilkan probabilitas untuk setiap kelas dalam dataset.

Model ini dikompilasi menggunakan Adam optimizer dengan learning rate kecil (0.0001) untuk memastikan pembelajaran stabil. Fungsi loss yang digunakan adalah binary_crossentropy, karena dataset melibatkan klasifikasi dengan dua kelas. Data augmentation diterapkan pada data latih menggunakan ImageDataGenerator, termasuk shear, zoom, dan horizontal flip, untuk meningkatkan generalisasi model. Model dilatih dengan memanfaatkan callback ModelCheckpoint untuk menyimpan model terbaik selama pelatihan berdasarkan akurasi pada data validasi. Setelah pelatihan selesai, model dievaluasi untuk menghitung akurasi dan loss pada data uji. Proses ini juga mencakup visualisasi prediksi dan analisis matriks kebingungan untuk menilai performa model dalam klasifikasi gambar. Pendekatan ini menunjukkan bagaimana DenseNet201 yang efisien dapat diadaptasi untuk menyelesaikan tugas klasifikasi khusus dengan memanfaatkan transfer learning dan teknik regulasi

seperti Dropout untuk mengoptimalkan performa dan mengurangi overfitting.

Selanjutnya, memanfaatkan model pre-trained ResNet50. ResNet50 merupakan salah satu arsitektur jaringan saraf konvolusional (CNN) yang terkenal karena kemampuannya dalam menangani masalah vanishing gradient melalui penggunaan blok residual. Model ini dirancang untuk memproses input gambar berukuran 224x224 piksel dengan tiga saluran warna (RGB). Dalam implementasi ini, lapisan awal dari ResNet50 yang telah dilatih sebelumnya pada dataset ImageNet dibekukan hingga lapisan ke-15 untuk mempertahankan fitur dasar yang telah dipelajari.

Setelah itu, lapisan tambahan ditambahkan di atas model dasar untuk menyesuaikan model dengan tugas klasifikasi pada dataset multi-cancer. Lapisan tambahan tersebut mencakup GlobalAveragePooling2D untuk meratakan keluaran dari lapisan konvolusi, Dropout layer dengan tingkat dropout sebesar 20% untuk mengurangi risiko overfitting, dan Dense layer sebagai lapisan akhir dengan fungsi aktivasi softmax, yang menghasilkan probabilitas untuk setiap kelas dalam dataset.

Model ini dikompilasi menggunakan Adam optimizer dengan learning rate sebesar 0.0001 untuk memastikan pembelajaran yang stabil. Fungsi loss yang digunakan adalah binary_crossentropy, yang cocok untuk tugas klasifikasi biner. Untuk meningkatkan performa model, dilakukan augmentasi data menggunakan ImageDataGenerator, seperti shear, zoom, dan horizontal flip. Model dilatih dengan callback ModelCheckpoint untuk menyimpan bobot terbaik berdasarkan akurasi validasi selama proses pelatihan.

Setelah pelatihan selesai, model dievaluasi menggunakan data uji untuk menghitung akurasi dan loss. Analisis lebih lanjut dilakukan dengan visualisasi matriks kebingungan dan laporan klasifikasi untuk mengevaluasi performa prediksi pada data uji. Pendekatan ini memanfaatkan kekuatan ResNet50 sebagai backbone yang efisien dalam mengekstraksi fitur visual, sementara lapisan tambahan memastikan model dapat beradaptasi dengan dataset yang spesifik. Teknik regulasi seperti Dropout dan augmentasi data diterapkan untuk meningkatkan generalisasi model dan mencegah overfitting.

Table 2. result run with 4 time DenseNet201

Model	Optimizer	LR	Batch Size	Epoch
DenseNet201 (95)	Adam	0.0001	32	5
DenseNet201 (99)	Adam	0.0001	32	5
ResNet50(37)	Adam	0.0001	32	5
VGG19(91)	Adam	0.0001	32	5

DenseNet201 adalah salah satu model konvolusional yang digunakan dalam eksperimen ini. Model ini dirancang untuk efisiensi dengan memanfaatkan koneksi langsung antara lapisan-lapisannya, sehingga memungkinkan aliran informasi yang lebih baik. DenseNet201 dilatih menggunakan dataset ImageNet dan dapat diadaptasi untuk tugas klasifikasi gambar melalui transfer learning. Model ini menerima input berupa gambar berukuran 224x224 piksel dengan tiga saluran warna (RGB) dan memprosesnya melalui lapisan-lapisan konvolusi untuk mengekstraksi fitur visual

penting. Setelah itu, output 4D dari model diratakan menggunakan GlobalAveragePooling2D sebelum diteruskan ke Dense layer untuk menghasilkan prediksi kelas. Dropout layer dengan tingkat dropout sebesar 50% diterapkan untuk mengurangi risiko overfitting selama pelatihan. Model ini dikompilasi menggunakan Adam optimizer dengan learning rate 0.0001 dan binary crossentropy sebagai fungsi loss.

Pada tabel di atas, terdapat beberapa konfigurasi DenseNet201 dengan pengaturan optimizer, learning rate, batch size, dan epoch yang sama. Konfigurasi pertama menggunakan DenseNet201 dengan batch size 32, learning rate 0.0001, dan melatih model selama 5 epoch. Konfigurasi kedua dengan batch size 32 epoch Konfigurasi ketiga dengan jumlah epoch 5 untuk membandingkan hasilnya dengan konfigurasi sebelumnya. Konfigurasi keempat tetap mempertahankan pengaturan yang sama, yaitu optimizer Adam, learning rate 0.0001, batch size 32, dan 5 epoch, untuk konsistensi analisis.


V. RESULT AND DISCUSSION

Pada bagian ini, hasil eksperimen yang dilakukan menggunakan tiga arsitektur model deep learning, yaitu DenseNet201, ResNet50, dan VGG19, akan dibahas secara mendalam. Setiap model diuji untuk tugas klasifikasi tiga kelas gambar kanker otak, yaitu brain_glioma, brain_menin, dan brain_tumor, dengan parameter yang telah ditentukan, seperti learning rate, optimizer Adam, batch size, dan jumlah epoch. Diskusi meliputi analisis grafik akurasi dan loss, performa model berdasarkan confusion matrix, serta kekuatan dan kelemahan masing-masing arsitektur dalam menangani dataset ini. Hasil ini memberikan gambaran menyeluruh mengenai efektivitas dan efisiensi ketiga model dalam tugas klasifikasi gambar multi-kelas.

A. Densenet201

Pada eksperimen ini, model DenseNet201 dengan learning rate 0.0001 menunjukkan performa yang sangat baik dalam tugas klasifikasi tiga kelas: brain_glioma, brain_menin, dan brain_tumor. Model dilatih menggunakan Adam optimizer, dengan batch size sebesar 32 dan jumlah epoch sebanyak 5. Hasil pelatihan menunjukkan akurasi pelatihan yang hampir sempurna dan akurasi validasi yang sangat tinggi, dengan konsistensi antara akurasi data latih dan validasi, yang mengindikasikan konvergensi yang baik tanpa overfitting.

Grafik akurasi pada gambar dibawah menunjukkan perkembangan yang signifikan selama pelatihan. Pada epoch pertama, akurasi validasi berada di sekitar 90%, namun dengan bertambahnya jumlah epoch, akurasi meningkat mendekati 98% pada akhir pelatihan. Akurasi data latih bahkan mencapai 99.50%, mencerminkan bahwa model berhasil mempelajari pola dengan sangat baik dari data latih. Tidak ada perbedaan signifikan antara akurasi latih dan validasi, menunjukkan bahwa model memiliki generalisasi yang kuat.




Gambar 8. Akurasi dan Loss Model DenseNet201

Grafik loss pada Gambar 8 menunjukkan tren penurunan loss yang konsisten baik untuk data latih maupun validasi. Pada epoch awal, nilai loss validasi sedikit lebih tinggi dibandingkan loss data latih, tetapi menurun dengan cepat seiring bertambahnya epoch. Pada akhir pelatihan, loss data validasi hampir mendekati loss data latih. Hal ini mengindikasikan bahwa model mempelajari pola dengan efisien tanpa mengalami overfitting.

Confusion matrix pada Gambar 9 menunjukkan performa prediksi model pada data uji. Dari total data uji, model berhasil memprediksi 280 data brain_glioma, 263 data brain_menin, dan 253 data brain_tumor dengan benar. Hanya terdapat 1 kesalahan prediksi brain_glioma, 2 kesalahan prediksi brain_menin, dan 1 kesalahan prediksi brain_tumor. Kesalahan ini sangat kecil dibandingkan jumlah data yang diprediksi dengan benar, menunjukkan bahwa model memiliki sensitivitas dan presisi yang sangat tinggi untuk ketiga kelas.

Berdasarkan hasil ini, model DenseNet201 dengan konfigurasi learning rate 0.0001, Adam optimizer, dan 5 epoch memberikan hasil yang optimal dalam tugas klasifikasi gambar tiga kelas ini. Kombinasi akurasi yang tinggi, loss yang rendah, dan kesalahan prediksi yang minimal menunjukkan bahwa model ini sangat cocok untuk digunakan dalam klasifikasi gambar multi-kelas pada dataset ini. Generalisasi model yang kuat pada data validasi juga memastikan bahwa model dapat bekerja dengan baik pada data yang belum pernah dilihat sebelumnya.




Gambar 9. Gambar Confusion Matrix DenseNet201

B. ResNet50

Pada eksperimen selanjutnya ada model ResNet50 dengan learning rate 0.0001 menunjukkan hasil pelatihan yang cukup menarik dalam tugas klasifikasi tiga kelas: brain_glioma, brain_menin, dan brain_tumor. Model dilatih menggunakan Adam optimizer, dengan batch size sebesar 32 dan jumlah epoch sebanyak 5.


Grafik akurasi yang ada pada Gambar 10 menunjukkan bahwa model berhasil mencapai akurasi data latih yang menunjukkan akurasi sebesar 37.25% pada akhir pelatihan. Namun, akurasi data validasi tetap stagnan di sekitar 35%-40%, yang mengindikasikan bahwa model mengalami overfitting. Model berhasil mempelajari pola dari data latih dengan sangat baik tetapi tidak mampu menangkap pola yang relevan pada data validasi, sehingga performanya menurun pada data yang belum pernah dilihat sebelumnya.



Gambar 10. Akurasi dan Loss ResNet50

Grafik loss mendukung temuan ini, di mana nilai loss data latih menurun secara signifikan hingga mendekati nol, sementara loss data validasi tetap tinggi dan tidak mengalami penurunan berarti. Hal ini menunjukkan bahwa model terlalu

fokus pada data latih tanpa memperhatikan generalisasi ke data validasi.



Gambar 11. Confusion Matrix ResNet50


Confusion matrix pada Gambar 11 menunjukkan performa model pada data uji. Model berhasil memprediksi dengan benar 189 data brain_glioma, 188 data brain_menin, dan 109 data brain_tumor. Namun, terdapat kesalahan prediksi yang cukup signifikan, seperti 92 kesalahan pada brain_glioma yang diprediksi sebagai brain_tumor, serta 145 kesalahan pada brain_tumor yang juga diprediksi sebagai brain_glioma. Kesalahan ini menunjukkan bahwa meskipun model dapat mempelajari pola dari data latih dengan sangat baik, kemampuan generalisasinya masih sangat terbatas.

Berdasarkan hasil ini, dapat disimpulkan bahwa model ResNet50 dengan konfigurasi learning rate 0.0001, Adam optimizer, dan 5 epoch tidak mampu memberikan performa optimal untuk dataset ini karena overfitting yang terjadi. Untuk meningkatkan generalisasi, perlu diterapkan strategi seperti regularisasi yang lebih kuat, augmentasi data tambahan, atau bahkan eksplorasi model lain yang lebih sesuai untuk dataset ini. Hal ini penting untuk memastikan bahwa model tidak hanya baik pada data latih tetapi juga dapat memberikan prediksi yang akurat pada data validasi dan uji.

C. Visual Geometry Group (VGG19)

Pada eksperimen ini, model VGG19 digunakan untuk klasifikasi gambar tiga kelas dengan parameter seperti learning rate sebesar 0.0001, optimizer Adam, batch size 32, dan jumlah epoch sebanyak 5. Berdasarkan hasil pelatihan, model menunjukkan peningkatan akurasi yang signifikan baik pada data latih maupun data validasi.


Grafik akurasi pada Gambar 12 menunjukkan bahwa pada epoch pertama, akurasi validasi mencapai sekitar 0.8 dan terus meningkat hingga mendekati akurasi latih pada akhir pelatihan, yaitu sekitar 0.9. Grafik loss menunjukkan penurunan konsisten pada data latih dan validasi, yang mencerminkan kemampuan model untuk belajar secara efektif tanpa tanda-tanda overfitting.



Gambar 12. Akurasi dan Loss VGG19

Confusion matrix seperti pada gambar 8 mengilustrasikan performa model dalam memprediksi tiga kelas, yaitu brain_glioma, brain_menin, dan brain_tumor. Model berhasil memprediksi dengan benar sebanyak 264, 222, dan 244 sampel pada masing-masing kelas. Namun, terdapat kesalahan prediksi di mana beberapa sampel dari kelas brain_menin diprediksi sebagai brain_tumor sebanyak 42 kasus, dan sampel dari kelas brain_glioma diprediksi salah sebanyak 17 kasus secara total.

Hasil Gambar 13 dibawah menunjukkan bahwa model VGG19 memiliki performa yang baik dalam mempelajari pola-pola pada dataset. Meskipun masih terdapat kesalahan prediksi, akurasi tinggi yang dicapai, serta grafik akurasi dan loss yang konsisten, menunjukkan potensi VGG19 untuk tugas klasifikasi gambar yang lebih kompleks. Dengan pengaturan parameter yang lebih optimal atau tambahan data pelatihan, performa model ini dapat ditingkatkan lebih lanjut



Gambar 13. Confusion Matrix VGG19

VI. KESIMPULAN

Kesimpulan dari penelitian ini menunjukkan bahwa model DenseNet201, ResNet50, dan VGG19 memiliki karakteristik dan performa yang berbeda dalam tugas klasifikasi tiga kelas gambar kanker otak: brain_glioma, brain_menin, dan brain_tumor. DenseNet201 menunjukkan performa terbaik dengan akurasi pelatihan 99,50% dan akurasi validasi mendekati 98%, serta loss yang konsisten menurun tanpa tanda-tanda overfitting. Model ini juga memiliki generalisasi yang kuat, dengan jumlah kesalahan prediksi yang minimal pada confusion matrix. Sebaliknya, ResNet50 mengalami overfitting, di mana akurasi validasi stagnan pada 35%-40%, meskipun akurasi pelatihan mencapai 37.25 %. Kesalahan prediksi yang signifikan menunjukkan bahwa model ini kurang mampu menangkap pola relevan pada data uji. Model VGG19 memberikan hasil yang cukup baik dengan akurasi validasi mendekati akurasi latih, yaitu sekitar 90%, serta tren loss yang stabil tanpa overfitting. Namun, terdapat kesalahan prediksi yang lebih tinggi dibandingkan DenseNet201, terutama pada kelas brain_menin yang sering diprediksi salah sebagai brain_tumor. Secara keseluruhan, DenseNet201 adalah model yang paling unggul untuk dataset ini, sedangkan ResNet50 memerlukan perbaikan strategi pelatihan, dan VGG19 menunjukkan potensi yang baik dengan peluang peningkatan melalui pengoptimalan parameter atau augmentasi data tambahan.

REFERENCES

- [1] G. S. Tandel *et al.*, "A review on a deep learning perspective in brain cancer classification," Jan. 01, 2019, *MDPI AG*. doi: 10.3390/cancers11010111.
- [2] A. De Boeck *et al.*, "Glioma-derived IL-33 orchestrates an inflammatory brain tumor microenvironment that accelerates glioma progression," *Nat Commun*, vol. 11, no. 1, Dec. 2020, doi: 10.1038/s41467-020-18569-4.
- [3] Anushka Shendkar, Shruti Yadav, Mayuri Puse, Nikita Rakh, and Prof. Revati Patil, "Programmed Multi-Classification of Brain Tumor Images Using Deep Neural Network," *International Journal of Advanced Research in Science, Communication and Technology*, pp. 45–47, May 2022, doi: 10.48175/IJARSCT-4009.
- [4] Dr. T. V. kumar, "CLASSIFICATION OF BRAIN CANCER TYPE USING MACHINE LEARNING," *Journal of Artificial Intelligence and Capsule Networks*, vol. 2019, no. 2, Dec. 2019, doi: 10.36548/jaicn.2019.2.006.
- [5] T. Sadad *et al.*, "Brain tumor detection and multi-classification using advanced deep learning techniques," *Microsc Res Tech*, vol. 84, no. 6, pp. 1296–1308, Jun. 2021, doi: 10.1002/jemt.23688.
- [6] K. Farmanfarma, M. Mohammadian, Z. Shahabina, S. Hassanipour, and H. Salehiniya, "BRAIN CANCER IN THE WORLD: AN EPIDEMIOLOGICAL REVIEW," *WCRJ*, Jun. 2019.
- [7] S. R. Sowrirajan, S. Balasubramanian, and R. S. P. Raj, "MRI Brain Tumor Classification Using a

- Hybrid VGG16-NADE Model,” *Brazilian Archives of Biology and Technology*, vol. 66, 2023, doi: 10.1590/1678-4324-2023220071.
- [8] S. Aulia and D. Rahmat, “INTERNATIONAL JOURNAL ON INFORMATICS VISUALIZATION journal homepage: www.joiv.org/index.php/joiv INTERNATIONAL JOURNAL ON INFORMATICS VISUALIZATION Brain Tumor Identification Based on VGG-16 Architecture and CLAHE Method,” *IJOIV*, Mar. 2022, [Online]. Available: www.joiv.org/index.php/joiv
- [9] A. Alshammari, “Construction of VGG16 Convolution Neural Network (VGG16_CNN) Classifier with NestNet-Based Segmentation Paradigm for Brain Metastasis Classification,” *Sensors*, vol. 22, no. 20, Oct. 2022, doi: 10.3390/s22208076.
- [10] W. Li, “Image Classification of Brain Tumor Based on Enhanced VGG 19 Convolutional Neural Network,” *Clin Onco*, vol. 6, no. 23, pp. 1–10, 2023.
- [11] C. Srinivas *et al.*, “Deep Transfer Learning Approaches in Performance Analysis of Brain Tumor Classification Using MRI Images,” *J Healthc Eng*, vol. 2022, 2022, doi: 10.1155/2022/3264367.
- [12] A. Raza *et al.*, “A Hybrid Deep Learning-Based Approach for Brain Tumor Classification,” *Electronics (Switzerland)*, vol. 11, no. 7, Apr. 2022, doi: 10.3390/electronics11071146.
- [13] A. M. Alhassan and W. M. N. Wan Zainon, “BAT Algorithm with fuzzy C-Ordered Means (BAFCOM) clustering segmentation and Enhanced Capsule Networks (ECN) for brain cancer MRI images classification,” *IEEE Access*, vol. 8, pp. 201741–201751, 2020, doi: 10.1109/ACCESS.2020.3035803.
- [14] F. Mercaldo, L. Brunese, F. Martinelli, A. Santone, and M. Cesarelli, “Object Detection for Brain Cancer Detection and Localization,” *Applied Sciences (Switzerland)*, vol. 13, no. 16, Aug. 2023, doi: 10.3390/app13169158.
- [15] G. Florimbi *et al.*, “Towards Real-Time Computing of Intraoperative Hyperspectral Imaging for Brain Cancer Detection Using Multi-GPU Platforms,” *IEEE Access*, vol. 8, pp. 8485–8501, 2020, doi: 10.1109/ACCESS.2020.2963939.
- [16] P. Afshar, K. N. Plataniotis, and A. Mohammadi, “Capsule Networks for Brain Tumor Classification based on MRI Images and Course Tumor Boundaries,” Nov. 2018, [Online]. Available: <http://arxiv.org/abs/1811.00597>
- [17] M. A. Khan *et al.*, “Multimodal brain tumor classification using deep learning and robust feature selection: A machine learning application for radiologists,” *Diagnostics*, vol. 10, no. 8, Aug. 2020, doi: 10.3390/diagnostics10080565.
- [18] M. M. Badža and M. C. Barjaktarović, “Classification of brain tumors from mri images using a convolutional neural network,” *Applied Sciences (Switzerland)*, vol. 10, no. 6, Mar. 2020, doi: 10.3390/app10061999.
- [19] S. Kumar and D. P. Mankame, “Optimization driven Deep Convolution Neural Network for brain tumor classification,” *Biocybern Biomed Eng*, vol. 40, no. 3, pp. 1190–1204, Jul. 2020, doi: 10.1016/j.bbe.2020.05.009.
- [20] H. H. Sultan, N. M. Salem, and W. Al-Atabany, “Multi-Classification of Brain Tumor Images Using Deep Neural Network,” *IEEE Access*, vol. 7, pp. 69215–69225, 2019, doi: 10.1109/ACCESS.2019.2919122.
- [21] J. Kang, Z. Ullah, and J. Gwak, “Mri-based brain tumor classification using ensemble of deep features and machine learning classifiers,” *Sensors*, vol. 21, no. 6, pp. 1–21, Mar. 2021, doi: 10.3390/s21062222.
- [22] K. Zhang, Y. Guo, X. Wang, J. Yuan, and Q. Ding, “Multiple feature reweight DenseNet for image classification,” *IEEE Access*, vol. 7, pp. 9872–9880, 2019, doi: 10.1109/ACCESS.2018.2890127.